Python 数据分析实践(Data Analysis Action)

Chap 5 网络数据收集和分析 Web Data Collection and Analysis

内容:

• 数据分析实战: 本地数据和Web数据

实践:

- 数据统计性描述
- 可视化绘图
- 网络数据采集和分析
 - 新闻网页数据采集
 - 股票金融数据分析
- · BeautifulSoup4
- · requests

实例:

• 实例1: 本地数据访问和分析 (csv和时间序列)

• 实例2: 新闻网页数据采集

• 实例3: 根据API获取股票金融数据

本节课讲述了从本地和Web获取数据,并进行数据的预处理、分析、可视化和磁盘保存。

两个重要的Python库处理网络资源:

• BeautifulSoup4

BeautifulSoup4是爬虫必学的技能,最主要的功能是从网页抓取数据,进行HTML/XML的解析。Beautiful Soup自动将输入文档转换为Unicode编码,输出文档转换为utf-8编码。

· requests

requests是一个重要的Python第三方库,访问和处理URL资源特别方便(Python内置的urllib模块使用比较麻烦,而且缺少很多实用的高级功能)

本章目录:

- 1. 读入本地磁盘数据,并进行数据分析、统计性描述、可视化绘图
- 2. 采集网络新闻标题数据,解析新闻网页内容
- 3. 获取Web数据(股票数据),并进行股票数据的分析和处理,存入本地磁盘

```
In [1]: # 必要准备工作: 导入库,配置环境等
#from __future__ import division
#import os, sys

# 导入库并为库起个别名
import numpy as np
import pandas as pd
from pandas import Series, DataFrame

# 启动绘图
%matplotlib inline
import matplotlib.pyplot as plt
```

实例1: 本地数据访问和分析 (csv和时间序列)

本地数据集1: 餐馆小费

tips.csv 是个关于餐馆小费记录的数据,包含七个字段(total_bill, tip, sex, smoker, day, time, size), 共计244条记录。

- 磁盘读入csv格式文件转为pd数据结构
- 对数据分析(缺失值-填充,清理,汇总描述,可视化绘图)
- 数据相关性分析
- 数据分组聚合

```
In [2]: import pandas as pd tips = 'data/tips.csv' data = pd.read_csv(tips) # 默认header='infer', 推导第一行是header, 小费记录始于第二行 print(len(data)) # 数据记录数量 data.head() # 预览最前5行记录 #data.tail() # 预览最后5行记录
```

244

Out[2]:

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4

```
In [3]: data.describe() # 数据的汇总描述
```

Out[3]:

	total_bill	tip	size
count	244.000000	244.000000	244.000000
mean	19.785943	2.998279	2.569672
std	8.902412	1.383638	0.951100
min	3.070000	1.000000	1.000000
25%	13.347500	2.000000	2.000000
50%	17.795000	2.900000	2.000000
75%	24.127500	3.562500	3.000000
max	50.810000	10.000000	6.000000

```
In [4]: stat = data.describe() # 数据的基本统计量 # 重点: 可以自己添加统计量信息 stat.loc['range'] = stat.loc['max'] - stat.loc['min'] # 极差 range stat.loc['var'] = stat.loc['std'] / stat.loc['mean'] # 变异系数,标准差/均值的离中趋势 stat.loc['IQR'] = stat.loc['75%'] - stat.loc['25%'] # 四分位数间距(极差) stat
```

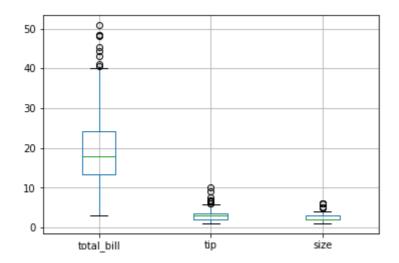
Out[4]:

	total_bill	tip	size
count	244.000000	244.000000	244.000000
mean	19.785943	2.998279	2.569672
std	8.902412	1.383638	0.951100
min	3.070000	1.000000	1.000000
25%	13.347500	2.000000	2.000000
50%	17.795000	2.900000	2.000000
75%	24.127500	3.562500	3.000000
max	50.810000	10.000000	6.000000
range	47.740000	9.000000	5.000000
var	0.449936	0.461478	0.370125
IQR	10.780000	1.562500	1.000000

```
[5]:
        # 数据的其他统计量
        # 数据的分布统计
        print(data.median()) # 数据的中位数
        data.mode() # 数据的众数
        data.quantile(0.1) # 数据的百分位数 data.quantile(q=0.5)
        # 数据的离中趋势度量
        data. skew() # 数据的偏度
        data.kurt() # 数据的峰度
        # 数据列之间的相关度量
        #协方差确定两个变量的关系,即正相关,负相关/无关
        #相关系数确定两个变量的关系&相关程度
        data. cov() #数据的协方差矩阵, 只表示线性相关的方向, 取值正无穷到负无穷, 协方差为正值说明正相关, 负值
        data.corr() # 数据的Pearson相关系数矩阵
        total bill
                    17.795
                    2.900
        tip
        size
                    2.000
        dtype: float64
Out[5]:
                total_bill
                            tip
                                   size
         total_bill 1.000000
                       0.675734
                               0.598315
               0.675734
                       1.000000
                               0.489299
            size 0.598315 0.489299
                               1.000000
   [6]: data['tip'].cov(data['size']) #计算指定变量之间的协方差
Out[6]: 0.6439064291978684
  \lceil 7 \rceil:
        data['tip'].corr(data['size']) #计算指定变量之间的相关系数
Out[7]: 0.4892987752303577
  [8]:
        data.columns
In
Out[8]: Index(['total bill', 'tip', 'sex', 'smoker', 'day', 'time', 'size'], dtype='object')
        data. columns. names # 此时每个列没有name
Out[9]: FrozenList([None])
```

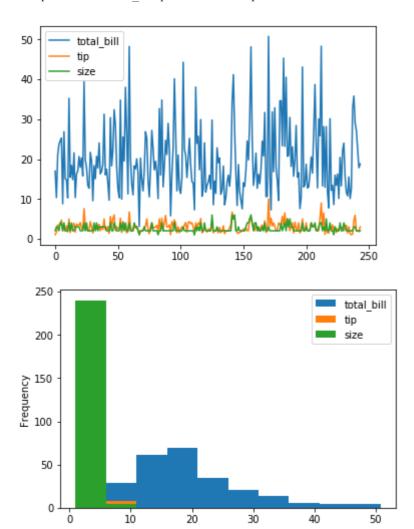
In [10]: # 启动绘图 %matplotlib inline import matplotlib.pyplot as plt data.boxplot(return_type='axes') # 画盒图,直接使用DataFrame的方法 #data.boxplot() # 画盒图,直接使用DataFrame的方法,需要屏蔽warning #data[['tip','size']].boxplot(return_type='axes') # 只对两个列画盒图

Out[10]: <matplotlib.axes._subplots.AxesSubplot at 0x7f951992b150>



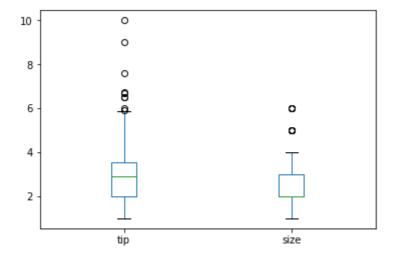
In [11]: data.plot.line() # 线图 data.plot.hist() # 直方图

Out[11]: <matplotlib.axes._subplots.AxesSubplot at 0x7f9512b8d050>



```
In [12]: # 几种盒图绘图 #data[['tip','size']].boxplot() # 盒图1, 同前面 #data[['tip','size']].plot(kind='box') # 盒图2 data[['tip','size']].plot.box() # 盒图3
```

Out[12]: <matplotlib.axes._subplots.AxesSubplot at 0x7f9512b00a10>



```
In [13]: # 其他多种图类型, tip, size, total_bill #data['tip'].plot.line() # 线图 1 #data['tip'].plot(kind='line') # 线图 2 #data['tip'].plot.hist() # 直方图 #data['tip'].plot.kde() # 密度图1 'kde' : Kernel Density Estimation plot #data['tip'].plot.density() # 密度图1 density,同上 #data['tip'].plot.pie() # 饼图
```

In [14]: # 相关性分析 data.corr() # method : {'pearson', 'kendall', 'spearman'},默认pearson

Out[14]:

	total_bill	tip	size
total_bill	1.000000	0.675734	0.598315
tip	0.675734	1.000000	0.489299
eizo.	0 508315	0.480200	1 000000

```
In [15]: data.corr(method='kendall') # method : {'pearson', 'kendall', 'spearman'}
```

Out[15]:

	total_bill	tip	size
total_bill	1.000000	0.517181	0.484342
tip	0.517181	1.000000	0.378185
size	0.484342	0.378185	1.000000

In [16]: | data. head()

Out[16]:

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4

思考: 数据分组进一步考虑: 消费与date (周一周末) 是否有关? 是否与time (中餐晚餐) 有关? 怎么做?

- 把day和time两个列转为行索引的外层和内层
- DataFrame的set_index函数会将其一个或多个列转换为行索引,并创建一个新的DataFrame。
- In [17]: # 考虑bill与date (周一周末)是否有关?是否与time (中餐晚餐)有关?
 - # 把day和time两个列转为行索引的外层和内层
 - # DataFrame的set index函数会将其一个或多个列转换为行索引,并创建一个新的DataFrame。

data2 = data.set_index(['day', 'time'])

data2. head()

Out[17]:

		total_bill	tip	sex	smoker	size
day	time					
Sun	Dinner	16.99	1.01	Female	No	2
	Dinner	10.34	1.66	Male	No	3
	Dinner	21.01	3.50	Male	No	3
	Dinner	23.68	3.31	Male	No	2
	Dinner	24.59	3.61	Female	No	4

In [18]: data2.tail()

Out[18]:

			total_bill	tip	sex	smoker	size
	day	time					
-	Sat	Dinner	29.03	5.92	Male	No	3
		Dinner	27.18	2.00	Female	Yes	2
		Dinner	22.67	2.00	Male	Yes	2
		Dinner	17.82	1.75	Male	No	2
	Thur	Dinner	18.78	3.00	Female	No	2

In [19]: # 选取周日Sun的消费统计汇总情况 data2.loc['Sun'].describe()

Out[19]:

	total_bill	tip	size
count	76.000000	76.000000	76.000000
mean	21.410000	3.255132	2.842105
std	8.832122	1.234880	1.007341
min	7.250000	1.010000	2.000000
25%	14.987500	2.037500	2.000000
50%	19.630000	3.150000	2.000000
75%	25.597500	4.000000	4.000000
max	48.170000	6.500000	6.000000

```
In [20]: # 选取周日Sun晚餐Dinner的消费统计汇总情况 data2.loc['Sun'].loc['Dinner'].describe() #data2.ix['Sun'].ix['Lunch'].describe() # 周日没有Lunch消费的记录
```

Out[20]:

	total_bill	tip	size
count	76.000000	76.000000	76.000000
mean	21.410000	3.255132	2.842105
std	8.832122	1.234880	1.007341
min	7.250000	1.010000	2.000000
25%	14.987500	2.037500	2.000000
50%	19.630000	3.150000	2.000000
75%	25.597500	4.000000	4.000000
max	48.170000	6.500000	6.000000

```
In [21]: # 对比工作日周五的午餐和晚餐消费均值
```

print (data2. loc['Fri']. loc['Lunch']. mean()) # 选取周五Fri午餐Lunch的消费统计汇总情况 print (data2. loc['Fri']. loc['Dinner']. mean()) # 选取周五Fri晚餐Dinner的消费统计汇总情况

```
total_bill 12.845714
tip 2.382857
size 2.000000
dtype: float64
total_bill 19.663333
```

total_bill 19.663333 tip 2.940000 size 2.166667

dtype: float64

```
In [22]: # 对比周五到周日的消费均值
```

```
print(data2.loc['Fri']['total_bill'].mean())
print(data2.loc['Sat']['total_bill'].mean())
print(data2.loc['Sun']['total_bill'].mean())
```

17. 151578947368417 20. 441379310344825

21. 4100000000000004

In [23]: # 交换索引 (行索引的内层和外层索引交换) data3 = data2. swaplevel (0, 1) # 交换索引后返回新的data3 data3. tail ()

Out[23]:

		total_bill	tip	sex	smoker	size
time	day					
Dinner	Sat	29.03	5.92	Male	No	3
	Sat	27.18	2.00	Female	Yes	2
	Sat	22.67	2.00	Male	Yes	2
	Sat	17.82	1.75	Male	No	2
	Thur	18.78	3.00	Female	No	2

In [24]: # 比较午餐Lunch和晚餐Dinner的消费统计汇总情况 print(data3.loc['Dinner'].describe()) print(data3.loc['Lunch'].describe())

	total_bill	tip	size
count	176.000000	176.000000	176.000000
mean	20. 797159	3. 102670	2.630682
std	9. 142029	1. 436243	0.910241
min	3.070000	1.000000	1.000000
25%	14. 437500	2.000000	2.000000
50%	18.390000	3.000000	2.000000
75%	25. 282500	3.687500	3.000000
max	50.810000	10.000000	6.000000
	total_bill	tip	size
count	68.000000	68.000000	68.000000
mean	17. 168676	2.728088	2. 411765
std	7.713882	1.205345	1.040024
min	7.510000	1.250000	1.000000
25%	12. 235000	2.000000	2.000000
50%	15.965000	2.250000	2.000000
75%	19.532500	3. 287500	2.000000
max	43.110000	6.700000	6.000000

其实,我们不必进行上面的操作,因为pandas提供了非常方便的groupby分组操作

groupby分组操作

pandas的DataFrame有groupby操作,可以非常方便对数据分组。不需要将多个列索引转换为行索引的情况下,可以直接对数据进行分组分析计算。

- df.groupby(['col2', 'col3']) # 首先,按照col2和col3的不同值进行分组
- df['col1'].describe() # 然后,统计col1的汇总情况

```
In [25]: # 添加"小费占总额百分比"列 data['tip_pct'] = data['tip'] / data['total_bill'] data[:6]
```

Out[25]:

	total_bill	tip	sex	smoker	day	time	size	tip_pct
0	16.99	1.01	Female	No	Sun	Dinner	2	0.059447
1	10.34	1.66	Male	No	Sun	Dinner	3	0.160542
2	21.01	3.50	Male	No	Sun	Dinner	3	0.166587
3	23.68	3.31	Male	No	Sun	Dinner	2	0.139780
4	24.59	3.61	Female	No	Sun	Dinner	4	0.146808
5	25.29	4.71	Male	No	Sun	Dinner	4	0.186240

```
In [26]: # 分组统计 data. groupby(['sex', 'smoker']). count() # 统计不同性别和是否抽烟的数量
```

Out[26]:

		total_bill	tip	day	time	size	tip_pct
sex	smoker						
Female	No	54	54	54	54	54	54
	Yes	33	33	33	33	33	33
Male	No	97	97	97	97	97	97
	Yes	60	60	60	60	60	60

In [27]: # 分组统计 data. groupby (['day', 'time']). count () # 统计不同天和不同餐时的数量

Out[27]:

		total_bill	tip	sex	smoker	size	tip_pct
day	time						
Fri	Dinner	12	12	12	12	12	12
	Lunch	7	7	7	7	7	7
Sat	Dinner	87	87	87	87	87	87
Sun	Dinner	76	76	76	76	76	76
Thur	Dinner	1	1	1	1	1	1
	Lunch	61	61	61	61	61	61

```
[28]:
           # 统计不同天和时间的平均情况
           data.groupby(['day','time']).mean()
Out[28]:
                          total_bill
                                        tip
                                                size
                                                       tip_pct
            day
                   time
             Fri
                 Dinner
                         19.663333
                                   2.940000
                                            2.166667
                                                     0.158916
                         12.845714
                                   2.382857
                                            2.000000
                                                     0.188765
                 Lunch
                        20.441379
                                   2.993103
             Sat Dinner
                                            2.517241
                                                     0.153152
            Sun
                 Dinner
                       21.410000
                                   3.255132
                                            2.842105
                                                     0.166897
                 Dinner
                         18.780000
                                   3.000000
                                            2.000000
                                                     0.159744
           Thur
                         17.664754
                                   2.767705
                                           2.459016
                                                     0.161301
                 Lunch
    [29]:
          # 只统计不同天和时间的tip平均情况
In
           data['tip'].groupby([data['day'], data['time']]).mean()
Out[29]:
          day
                 time
          Fri
                 Dinner
                           2.940000
                 Lunch
                           2.382857
          Sat
                 Dinner
                           2.993103
          Sun
                 Dinner
                           3.255132
          Thur
                Dinner
                           3.000000
                           2.767705
                 Lunch
          Name: tip, dtype: float64
    [30]:
          # 比较不同性别在不同天的午餐Lunch和晚餐Dinner的平均小费情况
In
           data['tip'].groupby([data['sex'], data['time']]).mean()
Out[30]:
          sex
                   time
          Female
                  Dinner
                             3.002115
                   Lunch
                             2.582857
          Male
                   Dinner
                             3.144839
                             2.882121
                   Lunch
          Name: tip, dtype: float64
    [31]:
           # 综合比较不同性别在周末午餐Lunch和晚餐Dinner的平均消费情况
           data.groupby(['sex', 'time']).mean()
Out[31]:
                            total_bill
                                          tip
                                                  size
                                                         tip_pct
                     time
               sex
           Female
                   Dinner
                           19.213077
                                     3.002115
                                              2.461538
                                                       0.169322
                    Lunch
                           16.339143
                                     2.582857
                                              2.457143
                                                        0.162285
             Male
                   Dinner
                           21.461452
                                     3.144839
                                              2.701613
                                                       0.155407
                          18.048485
                                     2.882121
                                              2.363636
                                                       0.166083
                    Lunch
    [32]:
           # 分组统计不同性别给出小费的比例情况
           grouped = data.groupby(['sex'])
           grouped. mean()
Out[32]:
                    total_bill
                                   tip
                                           size
                                                  tip_pct
               sex
           Female
                   18.056897
                             2.833448
                                       2.459770
                                                0.166491
```

Male

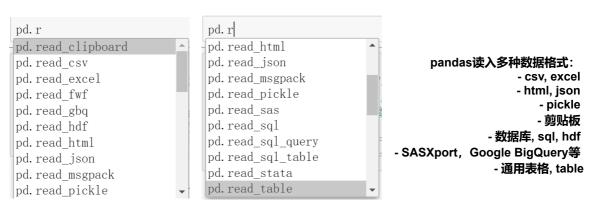
20.744076

3.089618

2.630573 0.157651

```
Out[33]: sex
         Female
                   0.166491
         Male
                   0.157651
         Name: tip_pct, dtype: float64
  [34]:
         # 首先,根据sex和smoker对tips进行分组
         grouped = data['tip_pct'].groupby([data['sex'], data['smoker']])
         grouped. mean()
Out[34]: sex
                 smoker
         Female
                 No
                           0.156921
                 Yes
                           0.182150
         Male
                           0.160669
                 No
                 Yes
                           0.152771
```

pandas可以读入的数据文件格式包括:



本地数据集2: 股票时间序列数据

[33]: # 不同性别给小费比例的均值

grouped['tip pct'].mean()

Name: tip_pct, dtype: float64

stock_px.csv 是个关于股票价格的时间序列数据,包含9只股票,对应9个字段(AA,AAPL,GE,IBM, JNJ,MSFT, PEP, SPX, XOM),时间从1990/2/1到2011/10/14,共计5472条记录。

美铝公司[AA], 苹果公司[AAPL], 通用电气[GE], 微软[MSFT], 强生[JNJ], 百事[PEP], 美国标准普尔500指数 (SPX), 埃克森美孚[XOM]

```
In [35]: import pandas as pd import numpy as np from datetime import datetime

f = 'data/stock_px.csv'
data = pd.read_csv(f, index_col='date') # 使用date列作为行索引
data.index = pd.to_datetime(data.index) # 将字符串索引转换成时间索引
print(len(data)) # 数据记录数量
data.head() # 预览最前5行记录
data.tail() # 预览最后5行记录
```

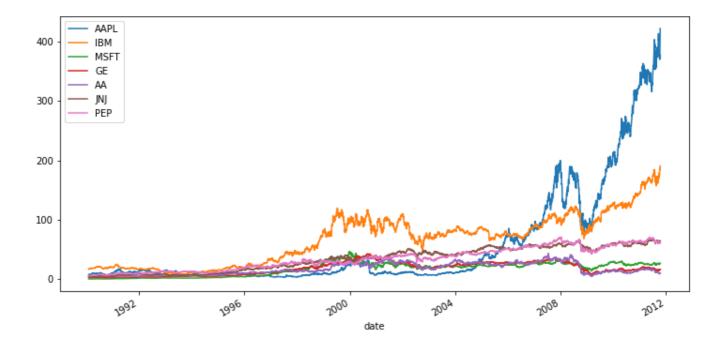
5472

Out[35]:

	AA	AAPL	GE	IBM	JNJ	MSFT	PEP	SPX	XOM
date									
2011-10-10	10.09	388.81	16.14	186.62	64.43	26.94	61.87	1194.89	76.28
2011-10-11	10.30	400.29	16.14	185.00	63.96	27.00	60.95	1195.54	76.27
2011-10-12	10.05	402.19	16.40	186.12	64.33	26.96	62.70	1207.25	77.16
2011-10-13	10.10	408.43	16.22	186.82	64.23	27.18	62.36	1203.66	76.37
2011-10-14	10.26	422.00	16.60	190.53	64.72	27.27	62.24	1224.58	78.11

```
In [36]: plt.rc('figure', figsize=(12,6)) data[['AAPL','IBM','MSFT','GE','AA','JNJ','PEP']].plot.line() # 绘曲线图
```

Out[36]: <matplotlib.axes._subplots.AxesSubplot at 0x7f9510761a10>



In [37]: # 重点了解苹果股票的基本统计量 data['AAPL']. describe()

```
Out[37]: count
                   5472.000000
                     57. 119313
          mean
          std
                     88.670423
          min
                      3.230000
          25%
                      8.760000
          50%
                     11.990000
          75%
                     68.017500
                    422.000000
          max
```

Name: AAPL, dtype: float64

```
[38]:
           # 苹果股票的其他统计量
In
           print(data['AAPL'].median()) # 数据的中位数
           print(data['AAPL']. mode()) # 数据的众数
           print(data['AAPL'].quantile(0.1)) # 数据的百分位数 data.quantile(q=0.5)
           #print(data['AAPL'].skew()) # 数据的偏度
           #print(data['AAPL'].kurt()) # 数据的峰度
           #data.mode? # 了解mode用法
           #data.quantile? # 了解quantile用法
           11.99
                9.28
           0
           dtype: float64
           6, 51
    [39]:
           # 各股票之间的相关统计量
In
           #data.cov() # 数据的协方差矩阵
           data.corr() # 数据的Pearson相关系数矩阵
Out[39]:
                        AA
                               AAPL
                                           GE
                                                    IBM
                                                             JNJ
                                                                     MSFT
                                                                                PEP
                                                                                          SPX
                                                                                                   XOM
              AA
                   1.000000
                            0.101313
                                     0.916804
                                               0.600211
                                                         0.685752
                                                                   0.776796
                                                                            0.634679
                                                                                      0.846861
                                                                                               0.567025
            AAPL
                  0.101313
                            1.000000
                                      0.142381
                                               0.749037
                                                         0.651564
                                                                   0.423274
                                                                            0.741942
                                                                                      0.410813
                                                                                               0.781369
                  0.916804
                            0.142381
                                      1.000000
                                               0.681659
                                                         0.717824
                                                                   0.875398
                                                                            0.652904
                                                                                      0.935598
                                                                                                0.581171
             IBM
                   0.600211
                            0.749037
                                      0.681659
                                                1.000000
                                                         0.902894
                                                                   0.871615
                                                                            0.885029
                                                                                      0.835484
                                                                                               0.855195
             JNJ
                  0.685752
                            0.651564
                                      0.717824
                                               0.902894
                                                         1.000000
                                                                   0.846906
                                                                            0.970478
                                                                                      0.845401
                                                                                               0.925600
            MSFT
                  0.776796
                            0.423274
                                      0.875398
                                               0.871615
                                                         0.846906
                                                                   1.000000
                                                                            0.781791
                                                                                      0.949715
                                                                                               0.730557
             PEP
                  0.634679
                            0.741942
                                      0.652904
                                               0.885029
                                                         0.970478
                                                                   0.781791
                                                                            1.000000
                                                                                      0.816477
                                                                                               0.964278
             SPX
                  0.846861
                            0.410813
                                      0.935598
                                               0.835484
                                                         0.845401
                                                                   0.949715
                                                                            0.816477
                                                                                      1.000000
                                                                                               0.761077
            XOM
                  0.567025 0.781369
                                               0.855195
                                                         0.925600
                                                                            0.964278
                                                                                      0.761077
                                                                                               1.000000
                                     0.581171
                                                                   0.730557
    [40]:
           data. head()
Out[40]:
                            AAPL
                                    GE
                                          IBM
                                                JNJ
                                                     MSFT
                                                           PEP
                                                                   SPX XOM
                 date
            1990-02-01
                                               4.27
                       4.98
                              7.86
                                   2.87
                                         16.79
                                                      0.51
                                                            6.04
                                                                 328.79
                                                                         6.12
            1990-02-02
                       5.04
                              8.00
                                   2.87
                                         16.89
                                               4.37
                                                      0.51
                                                            6.09
                                                                 330.92
                                                                         6.24
            1990-02-05
                       5.07
                              8.18
                                   2.87
                                         17.32
                                               4.34
                                                      0.51
                                                            6.05
                                                                 331.85
                                                                         6.25
            1990-02-06 5.01
                              8.12
                                   2.88
                                         17.56
                                               4.32
                                                      0.51
                                                            6.15
                                                                 329.66
                                                                         6.23
            1990-02-07 5.04
                              7.77
                                   2.91
                                         17.93 4.38
                                                      0.51
                                                            6.17
                                                                 333.75
                                                                         6.33
    [41]:
           data. tail()
Out [41]:
                              AAPL
                                       GE
                                              IBM
                                                         MSFT
                                                                 PEP
                                                                          SPX
                                                                               XOM
                         AA
                                                    JNJ
```

date

10.09

10.30

10.05

10.10

10.26 422.00

388.81

400.29

402.19

408.43

16.14

16.14

16.40

16.22

186.62

185.00

186.82

16.60 190.53 64.72

186.12 64.33

64.43

63.96

64.23

26.94

27.00

26.96

27.18

27.27

61.87

60.95

62.70

62.36

62.24

1194.89

1195.54

1207.25

1203.66

1224.58

76.28

76.27

77.16

76.37

78.11

2011-10-10

2011-10-11

2011-10-12

2011-10-13

2011-10-14

股票的时间序列数据分析

除了前面常用的统计、汇总、分组、可视化分析,对于股票数据,还可以进行更复杂的数据分析任务:

• 根据每天的收盘价返回对数收益率

```
In [42]: # 只取出苹果股票分析 df = pd.DataFrame(data['AAPL'], index=data.index, columns=['AAPL']) # data['AAPL']只是个Series df.tail()
```

Out[42]:

```
    date

    2011-10-10
    388.81

    2011-10-11
    400.29

    2011-10-12
    402.19

    2011-10-13
    408.43

    2011-10-14
    422.00
```

Out[43]:

```
        date
        AAPL
        Return

        2011-10-10
        388.81
        0.050128

        2011-10-11
        400.29
        0.029098

        2011-10-12
        402.19
        0.004735

        2011-10-13
        408.43
        0.015396

        2011-10-14
        422.00
        0.032685
```

```
In [44]: # 也可以使用向量化代码,在不使用循环的情况下得到相同的结果,即shift方法 df['Return2'] = np.log(df['AAPL'] / df['AAPL'].shift(1)) df[['AAPL', 'Return', 'Return2']].tail() # 最后面两列的值相同: 更紧凑和更容易理解的代码,而且是更快速的替代方案
```

Out[44]:

	AAPL	Return	Return2
date			
2011-10-10	388.81	0.050128	0.050128
2011-10-11	400.29	0.029098	0.029098
2011-10-12	402.19	0.004735	0.004735
2011-10-13	408.43	0.015396	0.015396
2011-10-14	422.00	0.032685	0.032685

```
In [45]: # 目前,一个对数收益率数据列就足够了,可以删除另一个列 del df['Return2'] # 删除列 df. tail()
```

Out[45]:

```
        date
        AAPL
        Return

        2011-10-10
        388.81
        0.050128

        2011-10-11
        400.29
        0.029098

        2011-10-12
        402.19
        0.004735

        2011-10-13
        408.43
        0.015396

        2011-10-14
        422.00
        0.032685
```

```
[46]:
         # 绘图更好地概览股价和波动率变化
          df[['AAPL', 'Return']].plot(subplots=True, style=['b','r'], figsize=(8,5))
Out[46]: array([<matplotlib.axes._subplots.AxesSubplot object at 0x7f95107b6a90>,
                 <matplotlib.axes. subplots.AxesSubplot object at 0x7f951061fd90>],
               dtype=object)
            400
                     AAPL
            300
            200
            100
              0
            0.25
                     Return
            0.00
           -0.25
           -0.50
           -0.75
```

```
In [47]: # 技术型股票交易者可能对移动平均值(即趋势)更感兴趣,
# 移动平均值很容易使用pandas的rolling_mean计算
#df['42d'] = pd.rolling_mean(df['AAPL'], window = 42) # 过时,现在不用
df['42d'] = df['AAPL'].rolling(window=42, center=False).mean()
#df['252d'] = pd.rolling_mean(df['AAPL'], window = 252) # 过时,现在不用
df['252d'] = df['AAPL'].rolling(window = 252, center=False).mean()
df[['AAPL', '42d', '252d']].tail()
```

Out [47]:

	AAPL	420	2520
date			
2011-10-10	388.81	384.502381	346.165278
2011-10-11	400.29	385.135476	346.569048
2011-10-12	402.19	385.735476	346.974008
2011-10-13	408.43	386.331190	347.395119
2011-10-14	422.00	387.319762	347.820754

In [48]: df[['AAPL', '42d', '252d']]. head() # 对于后两列,前面的数据为空

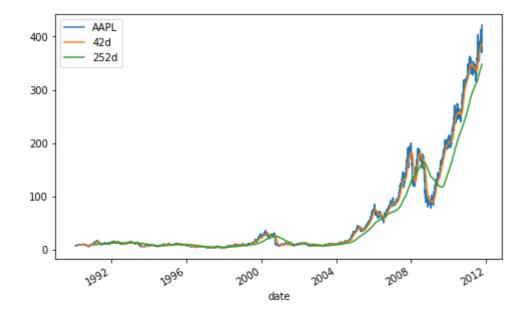
Out[48]:

AAPL 42d 252d

date			
1990-02-01	7.86	NaN	NaN
1990-02-02	8.00	NaN	NaN
1990-02-05	8.18	NaN	NaN
1990-02-06	8.12	NaN	NaN
1990-02-07	7.77	NaN	NaN

```
In [49]: # 包含两种趋势的典型股价图表绘图 df[['AAPL', '42d', '252d']].plot(figsize=(8,5))
```

Out[49]: <matplotlib.axes._subplots.AxesSubplot at 0x7f9510593fd0>



```
In [50]: # 期权交易者更喜欢的话题,对数收益率的移动历史标准差—即移动历史波动率 import math df['Mov_Vol'] = df['Return'].rolling(window=252,center=False).mean() * math.sqrt(252) df['Mov_Vol'].tail() # Mov_Vol列的数据在前面252行为空
```

Out[50]: date

 2011-10-10
 0. 017317

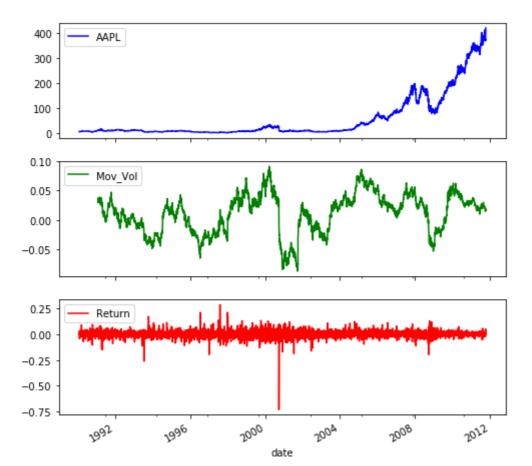
 2011-10-11
 0. 018475

 2011-10-12
 0. 018437

 2011-10-13
 0. 018953

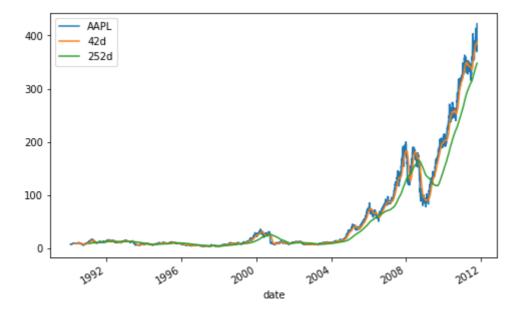
 2011-10-14
 0. 018474

Name: Mov_Vol, dtype: float64



In [52]: # 包含两种趋势的典型股价图表绘图 df[['AAPL', '42d', '252d']].plot(figsize=(8,5))

Out[52]: <matplotlib.axes._subplots.AxesSubplot at 0x7f95103adb10>



In [53]: df. tail()

Out[53]:

	AAPL	Return	42d	252d	Mov_Vol
date					
2011-10-10	388.81	0.050128	384.502381	346.165278	0.017317
2011-10-11	400.29	0.029098	385.135476	346.569048	0.018475
2011-10-12	402.19	0.004735	385.735476	346.974008	0.018437
2011-10-13	408.43	0.015396	386.331190	347.395119	0.018953
2011-10-14	422.00	0.032685	387.319762	347.820754	0.018474

保存数据

现在我们想把对苹果股票的分析数据保存下来,在以后的分析中继续使用。pandas的DataFrame的保存数据类型,参考前面表格中的读入数据类型。

In [54]: # 为了以后更容易导入数据,我们生成一个新的csv数据文本,并将所有数据行写入新文件 out_file = open('data/aapl.csv', 'w') df.to_csv(out_file) out_file.close()

实例2: 新闻网页数据采集

以中国新闻网 (http://www.chinanews.com/ (http://www.chinanews.com/)) 为例。

本课件分为如下两个部分:

- 1 单个页面新闻标题爬取: 主要介绍如何从一个页面中利用 Beautiful Soup 寻找感兴趣的内容
- 2 多页面新闻标题爬取
 - 2.1 滚动新闻页面爬取: 通过有规律的url进行爬取
 - 2.2 获取各板块头条新闻以及热点新闻: 自动获取不同板块地址进行内容爬取

In [55]: from IPython.display import IFrame url="http://www.chinanews.com/" IFrame(url, width='100%', height=400)

Out [55]:

设为首页 网站地图 企业邮箱 中国搜索 移动版

安徽 | 北京 | 重庆 | 福建 | 甘肃 | 贵州 | 广东 | 广西 | 海南 | 河北 | 河南 | 湖北 | 湖南 | 黑龙江 | 江苏 | 江西 | 吉林 | 辽宁 | 内蒙古 | 宁夏 | 青海

中國的問題 WWW.CHINANEWS.COM

2021年03月16日 星期二

滚动 时政 社会 财经 产经 金融 港澳 国际 汽车 English 中国侨网 中新经纬 图片 视频 直播 理论 生活 葡萄酒 微



习近平主持召开重磅会议 重点研究这两件

谈科技创新习近平这些话掷地有声 | 【每日一习话】脚踏实地

李克强主持会议确定政府工作报告 快速导航 中央有关部门有诚心有行动听取香 (1)

张勇:希望听取社会各界的意见 | 骆惠宁:选举委

北方沙尘天继续影响17省份 下半萬

In [56]: # 加载访问url资源的库 from bs4 import BeautifulSoup import requests

n [57]: url = "http://www.chinanews.com/"

html = requests.get(url) # 获取网页

soup = BeautifulSoup(html.content, "html.parser") # 将该网页转化为 BeautifulSoup 对象

#print(soup.prettify()) # 格式化打印网页,确认获取数据

1 单页面新闻标题爬取

大标题新闻的爬取

打开中国新闻网,我们首先对主页上最主要的新闻进行爬取,如下图所示,这些加粗部分是着重强调的新闻, 我们首先获取这部分数据



通过浏览器的开发者模式 (F12) ,我们可以定位到该部分内容在一个div框架下,如何找到这个div呢?其有唯一属性值:class = xwzxdd-dbt



习近平主持召开重磅会议 重点研究这两件大事李克强主持会议 确定政府工作报告重点任务分工中央有关部门有诚心有行动听取香港各方面意见北方沙尘天继续影响17省份下半月扩散条件有利喂药养羊、"瘦身"钢筋……这些黑幕被曝光!

上述过程中,会有少量的噪音数据,对比之后,我们可以通过一定的方法排除这些噪音数据

接下来,我们爬取要闻部分,即下图所示新闻

中新视频





探访武汉高龄患者康复驿站

美侨界驳"中国病毒"论

- □ 有爱公益视频 武警训练热血沸腾 男孩寄语医疗队
- 📵 美国首家隔离酒店 学者谈欧洲防疫 武磊确诊感染
- 📵 网络直播说相声 "隔离"火锅推出 校园消杀防疫
- 💷 万亩桃林花开正盛 线上春茶开园节 探访老牌煤矿

梦想从学习开始, 事业从实践起步。

罗达年

更多 🖸



• 严防境外疫情输入!北上广深进一步升级防控措施

- 警方通报武汉刑释人员进京事件:不追究黄某英法律责任
- 专家再谈血浆疗法: 监测可能风险 亟需更多捐献
- 核安全局: 海阳核电厂2号机组两起运行事件为0级事件
- 多支救援力量增援山西榆社山火火场 扑救仍在进行中
- 贵州江南等地有中到大雨 华北东北多地气温或创新高
- 湖北省委书记: 武汉要有序扩展无疫社区居民活动空间
- 多地"花式接待"返乡援鄂医护人员 网友:这个可以有
- 关注前沿汽车资讯 就在中新网汽车频道
- 拼关键州! 亿万富翁布隆伯格资助民主党1800万美元
- 外媒:东京奥运会组织方已开始草拟延期方案
- 中国专家医疗队受最高礼遇迎接 塞总统亲吻五星红旗
- 在美华人驳"中国病毒"论: 别有用心 华人需积极应对

div.new_con_yw 380×1106 自私! 疫情期间呆在家里

Elements

Sources Console

Network

Performance

Memory Application Security

Audits

▼<div id=

▼<div class="new_con_yw"

== \$0

- ▼<div class="new_con_border_b">
 - ▼
 - ▼
 - ▼

严防境外疫情輸入! 北上广深进一步升级防控措施

▶ ...

▶ ...

英雄烈士公祭办法征意见:不得利用公祭从事犯罪活动 国务院任免国家工作人员: 左力任司法部副部长 推广疫苗+筛查 距离"没有宫颈癌的未来"还有多远? 全国不到20人!如何缓解石窟寺考古人才断档之痛? 致盲性沙眼已被消灭 中国人群眼部疾病谱已发生重大变化 前2月主要经济指标呈大幅增长 2021中国经济开局怎么看 德法意也暂停接种阿斯利康疫苗 欧洲药监局将紧急开会 美意法德英发表联合声明: 不会让叙冲突再延续十年 "乱港"两案同日开庭 黎智英一案进入结案阶段 闭门举行!东京奥组委宣布圣火出发仪式以无观众形式举行 涉以危险武器袭击警察 参与美国会暴乱的两名男子被捕 韩法院重启李在镕狱中审判 三星"失去的十年"或成现实 美边境人道危机: 在押移民儿童数攀升 3000人超期羁押 A股小幅高开:沪指涨0.14%,医药板块活跃 透视美国强刺激:助力美国经济腾飞、薅全世界的羊毛? 新一线城市房租啥水平? 杭州比肩一线城市、沈阳最低 花卉产业恢复迅速 鲜花消费每逢佳节必爆单如何破局? 美三大股指集体收涨 道指、标普500指数均创新高 "保险+期货"迎发展新机遇 为乡村产业撑起"保护伞" 余额吊胃口、投入是黑洞 预付费卡为何"清零"难? 广西回应"泡药沃柑"事件:对健康不构成影响 国产剧掀"耽改"热: "腐文化"出圈,青少年入坑 揭秘故宫太和殿: 楠木从何而来? 装修有何深意? 广州"巨无霸"违章公馆争议多年终被拆除 11人被追责 "冷板凳""又难又穷"…如何摘掉基础学科旧"标签" "两弹城"保护沉疴: 院部面目全非 卖与企业后保护遇阻 小学生体测不合格不给毕业证 南通体测方案引关注 长大后我就成了你:98年"抱树女孩"当上人民警察

2.1 滚动新闻页面爬取



安徽 | 北京 | 重庆 | 福建 | 甘肃 | 贵州 | 广东 | 广西 | 海南 | 河北 | 河南 | 湖北 | 湖南 | 黑龙江 | 江苏 | 江西 | 吉林 |



- 点击滚动,进入新的网址为https://www.chinanews.com/scroll-news/news1.html
 (https://www.chinanews.com/scroll-news/news1.html),这里的新闻格式相对比较简单,我们可以先找到大的新闻框架(class= content_list的div),然后再定位到每一条新闻。
- 底部有页码栏,我们分别点击2和3,观察新打开的url,便可发现1-3页的url分别为:
 - https://www.chinanews.com/scroll-news/news1.html (https://www.chinanews.com/scroll-news/news1.html)
 - https://www.chinanews.com/scroll-news/news2.html (https://www.chinanews.com/scroll-news/news2.html)

https://www.chinanews.com/scroll-news/news3.html (https://www.chinanews.com/scroll-news/news3.html)

便可发现每一页的url基本相同,只有数字变化的规律,所以我们通过数字,手动构造1-10的每一页的url,来进行每一页新闻的自动爬取

```
url_scroll = soup.find(name='ul', attrs={"class":"nav_navcon"}).find('a')['href'] #获取顶部导航栏排
[60]:
       url scroll = "https:" + url scroll
                                           # https://www.chinanews.com/scroll-news/news1.html
       all scroll news = []
       for i in range (1, 11):
           url scroll = url scroll[:-6] + str(i) + ".html"
                                                                  # 每一页构造url
           print("Page %d, get news form %s" % (i, url scroll))
           html_scrol1 = requests.get(url_scrol1)
           soup_scrol1 = BeautifulSoup(html_scroll.content, "html.parser")
           news = soup_scroll.find(name="div", attrs={"class" :"content_list"})
           news = news. findAll(name="div", attrs={"class":"dd bt"})
           for n in news:
                 print (n. a. string)
                                     # 爬取新闻标题
               all scroll news. append (n. a. string)
           print("len news:", len(all_scroll_news))
           print()
```

Page 1, get news form https://www.chinanews.com/scroll-news/news1.html (https://www.chinanews.com/scroll-news/news1.html)

Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER.

len news: 125

Page 2, get news form https://www.chinanews.com/scroll-news/news2.html (https://www.chinanews.com/scroll-news/news2.html)

Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER.

1en news: 250

Page 3, get news form https://www.chinanews.com/scroll-news/news3.html (https://www.chinanews.com/scroll-news/news3.html)

Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER.

len news: 375

Page 4, get news form https://www.chinanews.com/scroll-news/news4.html (https://www.chinanews.com/scroll-news/news4.html)

Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER.

len news: 500

Page 5, get news form https://www.chinanews.com/scroll-news/news5.html (https://www.chinanews.com/scroll-news/news5.html)

Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER.

len news: 625

Page 6, get news form https://www.chinanews.com/scroll-news/news6.html (https://www.chinanews.com/scroll-news/news6.html)

Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER.

len news: 750

Page 7, get news form https://www.chinanews.com/scroll-news/news7.html (https://www.chinanews.com/scroll-news/news7.html)

Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER.

len news: 875

Page 8, get news form https://www.chinanews.com/scroll-news/news8.html (https://www.chinanews.com/scroll-news/news8.html)

Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER.

len news: 1000

Page 9, get news form https://www.chinanews.com/scroll-news/news9.html (https://www.chinanews.com/scroll-news/news9.html)

Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER.

len news: 1125

Page 10, get news form https://www.chinanews.com/scroll-news/news10.html (https://www.chinanews.com/scroll-news/news10.html)

Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER.

1en news: 1250

因为涉及到编码问题,上述单元格运行会产生 Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER. 的警告

但对我们的结果没有影响。如果不想产生类似警告,可以修改下面两行加注释的代码

```
In [61]: # html_scroll = requests.get(url_scroll)
# soup_scroll = BeautifulSoup(html_scroll.content, "html.parser", from_encoding="iso-8859-1") # 编码
# news = soup_scroll.find(name="div", attrs={"class":"content_list"})
# news = news.findAll(name="div", attrs={"class":"dd_bt"})

# for n in news:
# print(n.a.string.encode("iso-8859-1").decode("utf-8")) # 编码转换
```

In [62]: len(all scroll news),all scroll news[:10] # 查看数据

Out [62]: (1250,

['东京奥组委确认火炬接力将如期举行 不对普通观众开放',

- '驻尼日利亚使馆为接种国产疫苗人员赴华提供便利',
- '阿根廷一男子抢劫华人超市 被店员和顾客合力擒住'
- '王晶、陈百祥等发声 十几位香港演艺人士挺"爱国者治港"',
- '无线网络信号不好还总掉线?我国专家有了新解决方案',
- '安徽庐剧"接棒"传承焕生机 专业院团青年演员占比近半'
- '探索全新合作模式 松下携手中国石化建立冬奥合作示范店',
- '意大利暂停阿斯利康疫苗 疫情期间抗焦虑药物销量大增',
- '云南畹町边检站破获一起特大毒品案 缴毒近12公斤',
- '3月下半月中国大部扩散条件较为有利 空气质量以优良为主'])

2.2 获取各板块头条新闻以及热点新闻



对于这类每页有大致相同结构的网页,虽然每个板块url不能直接构造,但是我们可以借助其属性href获取每一页的url

```
Elements
                                 Console
                                        Sources
                                               Network
                                                       Performance
                                                                Memory
                                                                       Application
                               <!! class style=</pre>
                                margin: 0 18px;
                                  href="//www.chinanews.com/china/" 时政</a> == $0
                              ▶ ...
[63]: | all news = []
      navbar = soup.find(name='ul',attrs={"class":"nav_navcon"}).findAll("a")
      for nav in navbar[1:14]: # 取第一栏
          print (nav. string)
          if nav['href'][:5]!="http:":
              url_nav = "http:" + nav['href'] # 获取改板块的url
          print(url_nav)
          html nav = requests.get(url nav)
          soup nav = BeautifulSoup(html nav.content, "html.parser")
          count = 0 # 控制打印新闻条数
          for n in soup nav.findAll("li") + soup nav.findAll("em") + soup nav.findAll("h1"): # 寻找新闻
              if n. a and n. a. string and len(n. a. string) > 7:
                 all news. append (n. a. string)
                 if count < 3:
                     print (n. a. string)
                     count += 1
          print()
      print(len(all news))
      肘政
      http://www.chinanews.com/china/ (http://www.chinanews.com/china/)
      Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER.
      陕西省首个黄河流域生态环境司法保护基地揭牌
      跨越十七载:一群台湾人与四川凉山的"达祖"情缘
      中国城市人均公园绿地面积达14.8平方米
      国际
      http://www.chinanews.com/world/ (http://www.chinanews.com/world/)
      Some characters could not be decoded, and were replaced with REPLACEMENT CHARACTER.
       • 意大利暂停阿斯利康疫苗 疫情期间抗焦虑药物销量大增
       • 美圣地亚哥汽车冲撞行人事故致3死6伤 司机已被捕
       • 土耳其向叙利亚投放军事设备修筑防御工事 俄表示担忧
```

国际

中新经纬

滚动

ninanews.com

English 中国侨网

时政

社会

图片

财经

视频

社会

http://www.chinanews.com/society/ (http://www.chinanews.com/society/)

```
n [64]: # 我们生成一个新的数据文本,并将所有新闻标题写入新文件 with open('data/all_news.txt', 'w') as f:
    for i in range(len(all_news)):
        f.write(str(all_news[i])+'\n')
    f.close()
```

实例3: 根据API获取股票金融数据

采集数据

下面的例子中采集股票数据,需要安装pandas-datareader

conda install pandas-datareader

加载模块如下

from pandas_datareader import data

```
In [65]: # 使用Yahoo Finance的API获取四个公司的股票数据
import pandas as pd
import numpy as np
from pandas_datareader import data

codes = ['AAPL', 'IBM', 'MSFT', 'GOOG'] # 四个股票
all_stock = {}
for ticker in codes:
    all_stock[ticker] = data.get_data_yahoo(ticker, start='1/1/2018') # 默认从2010年1月起始

volume = pd. DataFrame({tic: data['Volume'] for tic, data in all_stock.items()})
open = pd. DataFrame({tic: data['Open'] for tic, data in all_stock.items()})
high = pd. DataFrame({tic: data['High'] for tic, data in all_stock.items()})
low = pd. DataFrame({tic: data['Low'] for tic, data in all_stock.items()})
close = pd. DataFrame({tic: data['Close'] for tic, data in all_stock.items()})
price = pd. DataFrame({tic: data['Adj Close'] for tic, data in all_stock.items()}) # 已调整或者复考
```

In [66]:

all_stock['AAPL'].head() # 显示前5行数据

Out[66]:

	High	Low	Open	Close	Volume	Adj Close
Date						
2018-01-02	43.075001	42.314999	42.540001	43.064999	102223600.0	41.380238
2018-01-03	43.637501	42.990002	43.132500	43.057499	118071600.0	41.373032
2018-01-04	43.367500	43.020000	43.134998	43.257500	89738400.0	41.565216
2018-01-05	43.842499	43.262501	43.360001	43.750000	94640000.0	42.038452
2018-01-08	43.902500	43.482498	43.587502	43.587502	82271200.0	41.882305

In [67].

all_stock['AAPL'].tail() #显示后5行数据

Out[67]:

	High	Low	Open	Close	Volume	Adj Close
Date						
2021-03-09	122.059998	118.790001	119.029999	121.089996	129159600.0	121.089996
2021-03-10	122.169998	119.449997	121.690002	119.980003	111760400.0	119.980003
2021-03-11	123.209999	121.260002	122.540001	121.959999	102753600.0	121.959999
2021-03-12	121.169998	119.160004	120.400002	121.029999	87963400.0	121.029999
2021-03-15	124.000000	120.430000	121.410004	123.989998	92590555.0	123.989998

```
IBM
                           AAPL
                                                 MSFT
                                                             GOOG
                 Date
            2018-01-02 41.380238
                                  132.039154
                                             82.194328
                                                        1065.000000
            2018-01-03 41.373032
                                  135.668625
                                             82.576843
                                                        1082.479980
            2018-01-04 41.565216
                                 138.416412
                                             83.303658
                                                        1086.400024
            2018-01-05 42.038452 139.092651
                                             84.336464
                                                        1102.229980
            2018-01-08 41.882305 139.931534
                                             84.422516
                                                        1106.939941
   [69]:
           all_stock['AAPL']. head()
Out[69]:
                           High
                                                Open
                                                          Close
                                                                     Volume
                                                                              Adj Close
                                      Low
                 Date
            2018-01-02 43.075001 42.314999
                                                                 102223600.0
                                            42.540001
                                                       43.064999
                                                                              41.380238
            2018-01-03 43.637501
                                 42.990002 43.132500
                                                       43.057499
                                                                  118071600.0
                                                                             41.373032
            2018-01-04 43.367500 43.020000 43.134998
                                                                  89738400.0
                                                                             41.565216
                                                       43.257500
            2018-01-05 43.842499
                                 43.262501
                                            43.360001
                                                       43.750000
                                                                  94640000.0
                                                                              42.038452
            2018-01-08 43.902500 43.482498 43.587502
                                                       43.587502
                                                                  82271200.0 41.882305
    [70]:
           AAPL = all_stock['AAPL']
In
           1en (AAPL)
           AAPL. head()
Out[70]:
                           High
                                       Low
                                                Open
                                                          Close
                                                                     Volume
                                                                             Adj Close
                 Date
            2018-01-02
                       43.075001
                                 42.314999
                                            42.540001
                                                       43.064999
                                                                 102223600.0
                                                                              41.380238
            2018-01-03
                       43.637501
                                 42.990002
                                            43.132500
                                                       43.057499
                                                                  118071600.0
                                                                              41.373032
            2018-01-04
                      43.367500
                                 43.020000
                                            43.134998
                                                       43.257500
                                                                  89738400.0
                                                                              41.565216
            2018-01-05 43.842499
                                 43.262501
                                            43.360001
                                                       43.750000
                                                                  94640000.0
                                                                              42.038452
            2018-01-08 43.902500 43.482498 43.587502
                                                       43.587502
                                                                  82271200.0 41.882305
    \lceil 71 \rceil:
           # 为了以后更容易导入数据,我们生成一个新的csv数据文本,并将所有数据行写入新文件
           AAPL. to csv ('data/AAPL-0.csv')
```

[68]:

Out[68]:

price. head()

```
In [72]: # 有时网络访问不稳定,因此读入已经保存的AAPL股票数据
import numpy as np
import pandas as pd
f = 'data/AAPL-0.csv'

data = pd.read_csv(f, index_col='Date') # 使用date列作为行索引
data.index = pd.to_datetime(data.index) # 将字符串索引转换成时间索引
AAPL = data
print(len(AAPL))
AAPL.tail() # 显示后5行数据
```

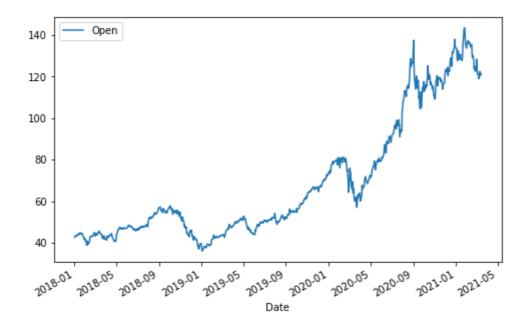
805

Out[72]:

	High	Low	Open	Close	Volume	Adj Close
Date						
2021-03-09	122.059998	118.790001	119.029999	121.089996	129159600.0	121.089996
2021-03-10	122.169998	119.449997	121.690002	119.980003	111760400.0	119.980003
2021-03-11	123.209999	121.260002	122.540001	121.959999	102753600.0	121.959999
2021-03-12	121.169998	119.160004	120.400002	121.029999	87963400.0	121.029999
2021-03-15	124.000000	120.430000	121.410004	123.989998	92590555.0	123.989998

In [73]: # 包含两种趋势的典型股价图表绘图 AAPL[['Open']].plot(figsize=(8,5))

Out[73]: <matplotlib.axes._subplots.AxesSubplot at 0x7f950afbc690>



使用Yahoo Finance的API获取沪深股市的股票数据

[74]: # 使用Yahoo Finance的API获取沪深股市的股票数据 import pandas as pd import numpy as np #from pandas_datareader import data import pandas_datareader as pdr

Out[74]:

	High	Low	Open	Close	Volume	Adj Close
Date						
2016-03-17	234.100006	228.300003	230.000000	229.559998	2882095.0	212.597107
2016-03-18	232.259995	225.779999	232.000000	226.000000	7056894.0	209.300140
2016-03-21	232.020004	226.649994	226.660004	231.979996	3854745.0	214.838272
2016-03-22	238.179993	231.500000	232.259995	234.490005	4176661.0	217.162796
2016-03-23	237.000000	232.679993	235.199997	234.970001	2141206.0	217.607315

Maotai = pdr.get_data_yahoo('600519.SS') # 茅台股票代码+沪市

[75]:

Maotai.tail()

Maotai.head()

Out[75]:

	High	Low	Open	Close	Volume	Adj Close
Date						
2021-03-09	2000.000000	1900.180054	1955.000000	1936.989990	8226581.0	1936.989990
2021-03-10	1999.869995	1967.000000	1977.000000	1970.010010	5117174.0	1970.010010
2021-03-11	2079.989990	1961.479980	1976.989990	2048.000000	5676897.0	2048.000000
2021-03-12	2077.000000	2002.010010	2070.000000	2026.000000	4032251.0	2026.000000
2021-03-16	1997.989990	1965.000000	1974.930054	1983.660034	1411958.0	1983.660034

[76]: # 使用Yahoo Finance的API获取沪深股市的股票数据

import pandas as pd import numpy as np $from\ pandas_datareader\ import\ data$ import pandas_datareader as pdr

获取

PUFA = data.get_data_yahoo('600000.SS') # 浦发银行股票代码600000+沪市SS PUFA. head()

Out[76]:

	High	Low	Open	Close	Volume	Adj Close
Date						
2016-03-17	12.720279	12.202797	12.454545	12.377622	98149211.0	10.799910
2016-03-18	12.587412	12.342657	12.440559	12.475524	80062794.0	10.885332
2016-03-21	12.762237	12.433566	12.433566	12.629370	60062190.0	11.019567
2016-03-22	13.027972	12.601398	12.650349	12.692307	62577959.0	11.074484
2016-03-23	12.832167	12.629370	12.699300	12.678321	39798036.0	11.062279

In [77]: PUFA. tail()

Out[77]:

	High	Low	Open	Close	Volume	Adj Close
Date						
2021-03-09	10.90	10.65	10.78	10.73	83584061.0	10.73
2021-03-10	10.79	10.63	10.76	10.72	50512161.0	10.72
2021-03-11	10.97	10.76	10.77	10.90	76816962.0	10.90
2021-03-12	11.03	10.82	10.89	10.90	79235629.0	10.90
2021-03-16	11.24	11.05	11.05	11.09	30280655.0	11.09

In [78]: # 使用Yahoo Finance的API获取沪深股市的股票数据

import pandas as pd import numpy as np

 $from\ pandas_datareader\ import\ data$

获取探路者股票代码是: 300005, 深市SZ

EXP = data.get_data_yahoo('300005.SZ') # 探路者股票代码是: 300005, 创业板股票代码以300打头 EXP. head()

Out[78]:

	High	Low	Open	Close	Volume	Adj Close
Date						
2016-03-17	11.173333	10.593333	10.660000	11.140000	21816462.0	10.808415
2016-03-18	11.886666	11.153333	11.166666	11.733333	30138343.0	11.384086
2016-03-21	12.126666	11.666666	11.940000	12.100000	30252804.0	11.739841
2016-03-22	12.320000	11.833333	11.906666	12.086666	25129914.0	11.726903
2016-03-23	12.400000	11.866666	12.166666	12.146666	21871434.0	11.785117

In [79]: EXP. tail()

Out[79]:

	High	Low	Open	Close	Volume	Adj Close
Date						
2021-03-09	7.06	6.67	7.00	6.85	12553447.0	6.85
2021-03-10	6.88	6.70	6.85	6.85	9440310.0	6.85
2021-03-11	6.90	6.68	6.89	6.72	11100550.0	6.72
2021-03-12	6.85	6.60	6.71	6.82	9638400.0	6.82
2021-03-16	6.75	6.60	6.72	6.63	2910200.0	6.63